

阅读仓库根目录的 `PROJECT_SPEC.md`，在现有 M0 和 M1-A 基础上，只完成 **M1-B: ERA5 NetCDF 内容解析与数据完整性校验**。

本次任务的目标是验证实际下载文件的结构和语义是否符合 ERA5 请求。不要进入 M2 的特征工程、数据切分、样本窗口或模型代码。

一、任务范围

本次只实现：

1. 使用 xarray 打开 ERA5 NetCDF 文件；
2. 提取文件结构和元数据摘要；
3. 校验时间坐标；
4. 校验纬度和经度坐标；
5. 校验变量集合；
6. 校验变量单位；
7. 校验数据维度和形状；
8. 校验缺失值和有限值比例；
9. 校验文件内容与 manifest 请求信息是否一致；
10. 增加 CLI 校验命令；
11. 增加不访问网络的单元测试和集成测试。

本次不要实现：

- 相对湿度计算；
- 风速派生；
- 单位转换后的训练数据；
- 累计降水；
- 时间周期特征；
- 空间裁剪或插值；
- 训练集、验证集和测试集划分；
- 标准化；
- 滑动窗口；
- PyTorch Dataset；
- 模型、训练、评估或 FastAPI。

二、依赖

在 `pyproject.toml` 中加入完成 NetCDF 读取所需的最小依赖。

优先考虑：

- `xarray`
- 一个明确选择的 NetCDF 后端，例如 `netCDF4` 或 `h5netcdf`

不要同时无理加入多个功能重叠的后端。

锁文件必须同步更新。

三、模块设计

下载逻辑与内容校验逻辑必须分离。

建议增加类似模块：

```
src/weather_ai/data/  
├── validation.py  
├── inspection.py  
└── schemas.py
```

职责建议：

- `inspection.py`：打开数据集并提取结构化摘要；
- `validation.py`：执行校验规则；
- `schemas.py`：定义校验结果、问题严重级别和数据摘要模型。

不要让 CLI 函数直接实现 xarray 业务逻辑。

四、文件读取要求

使用 xarray 打开 NetCDF 时：

1. 默认采用惰性读取；
2. 使用上下文管理或明确关闭 Dataset；
3. 不一次性将完整文件加载到内存；
4. 不修改原始 NetCDF 文件；
5. 不对原始文件进行原地修复；
6. 文件无法打开时给出明确错误；
7. 校验失败时返回非零退出码。

五、变量名称处理

不要假设 CDS 请求中的长变量名一定与 NetCDF 内部变量名完全相同。

需要建立显式映射，例如：

```
2m_temperature           → t2m  
2m_dewpoint_temperature  → d2m  
surface_pressure         → sp  
10m_u_component_of_wind  → u10  
10m_v_component_of_wind  → v10
```

具体映射必须以实际 ERA5 文件和官方变量定义为依据。

要求：

- 映射集中管理；
- 未知变量明确报错；
- 不通过模糊字符串匹配猜测变量；
- 校验结果同时报告请求名称和文件内部名称。

六、时间校验

至少检查：

1. 是否存在明确的时间坐标；
2. 时间值能否解析；
3. 时间是否单调递增；
4. 是否存在重复时间戳；
5. 是否符合逐小时分辨率；
6. 是否覆盖配置所要求的完整月份；
7. 实际时间点数量是否符合对应月份；
8. 时区语义应记录为 UTC；
9. 不允许静默补齐缺失时间。

闰年和不同月份天数必须正确处理，不能硬编码为 30 天。

预期小时数应由日历计算：

天数 × 24

七、空间坐标校验

至少检查：

1. 是否存在纬度坐标；
2. 是否存在经度坐标；
3. 坐标是否为一维规则轴；
4. 纬度值是否位于 `[-90, 90]`；
5. 经度值是否位于合法范围；
6. 纬度可能递增或递减，两种都应被识别并记录；
7. 坐标是否包含重复值；
8. 数据范围是否覆盖配置请求区域；
9. 目标区域与文件坐标之间的浮点差异应采用明确容差；
10. 不在本阶段重新排序坐标。

八、维度和形状校验

对每个请求变量检查：

- 是否包含时间维；
- 是否包含纬度维；
- 是否包含经度维；

- 形状是否与坐标长度一致；
- 是否存在未预期的额外维度；
- 所有请求变量的核心网格是否兼容。

允许记录单值辅助坐标，但不得静默忽略影响数据含义的额外维度。

九、单位校验

为每个变量定义预期原始单位，例如：

- 温度和露点温度：通常为 K；
- 地面气压：通常为 Pa；
- 风分量：通常为 m s^{-1} 。

要求：

1. 从 NetCDF 属性读取单位；
2. 与预期单位进行显式比较；
3. 单位缺失时至少产生 warning；
4. 单位冲突时产生 error；
5. 本阶段只校验单位，不执行摄氏度或百帕转换；
6. 不根据数值范围猜测单位并静默修正。

十、数值质量校验

对每个变量至少统计：

- 元素总数；
- NaN 数量；
- 非有限值数量；
- 缺失比例；
- 最小值；
- 最大值；
- 平均值；
- 标准差。

为避免加载完整大文件，可以：

- 使用 xarray 的分块和归约；
- 或提供可配置抽样校验模式。

但对本次一个月小样本，应支持完整统计。

至少设置宽松但合理的物理安全范围，用于发现明显错误，例如：

- 温度必须为有限合理范围；
- 气压不能为负；
- 风速分量不能出现明显不可解释的数量级。

这些范围只是数据完整性保护，不应被描述为严格气象质量控制标准。

十一、manifest 一致性

从 manifest 读取请求信息，并检查：

- 文件路径；
- SHA-256；
- 文件大小；
- 数据集名称；
- 请求年月；
- 请求变量；
- 请求区域；
- 输出格式。

需要重新计算文件 SHA-256，并与 manifest 比较。

manifest 不存在、文件哈希不匹配或文件大小不一致时，应产生明确错误。

十二、CLI

增加类似命令：

```
uv run weather-ai data validate
--file data/raw/<FILE>.nc
--manifest data/manifests/<MANIFEST>.json
```

也可以允许通过配置自动定位文件，但必须避免歧义。

支持：

```
uv run weather-ai data validate
--file data/raw/<FILE>.nc
--manifest data/manifests/<MANIFEST>.json
--output-json artifacts/data-validation/<NAME>.json
```

CLI 输出至少包括：

- 文件路径；
- 数据集维度；
- 时间范围；
- 经纬度范围；
- 请求变量与内部变量映射；
- 单位；
- 缺失率；
- warning 数量；
- error 数量；
- 最终校验状态。

返回码：

- 校验通过：0；
- 存在 error：非 0；
- 只有 warning：默认仍为 0，但结果中必须明确标记。

十三、校验结果模型

定义类型化结果，例如：

```
ValidationIssue:
    severity: error | warning | info
    code: str
    message: str
    variable: str | None

DatasetSummary:
    dimensions: dict[str, int]
    time_start: datetime
    time_end: datetime
    latitude_min: float
    latitude_max: float
    longitude_min: float
    longitude_max: float
    variables: list[VariableSummary]

ValidationReport:
    status: passed | passed_with_warnings | failed
    issues: list[ValidationIssue]
    dataset: DatasetSummary
```

字段名称可按现有项目风格调整，但必须稳定、可序列化并有类型注解。

十四、测试要求

所有 CI 测试不得访问外网。

使用 xarray 在临时目录动态生成微型 NetCDF fixture，避免提交大型二进制文件。

至少覆盖：

1. 合法微型 ERA5 风格 NetCDF 校验通过；
2. 文件无法打开时失败；
3. 请求变量缺失时失败；
4. 未知变量映射时失败；
5. 时间不连续时失败；
6. 时间重复时失败；
7. 月份小时数不完整时失败；
8. 经纬度超出合法范围时失败；

9. 请求区域未被文件覆盖时失败；
10. 单位冲突时失败；
11. 单位缺失时产生 warning；
12. 变量维度不一致时失败；
13. 全 NaN 变量时失败；
14. manifest SHA-256 不匹配时失败；
15. manifest 文件大小不匹配时失败；
16. CLI 成功时退出码为 0；
17. CLI 校验失败时退出码非 0；
18. 原始 NetCDF 在校验前后哈希不变。

至少添加一个集成测试：

```
微型 NetCDF
→ manifest
→ CLI validate
→ JSON 校验报告
```

十五、真实数据验收

如果仓库中已经存在由 M1-A 实际下载的小样本文件：

1. 使用新命令校验该文件；
2. 不提交原始 NetCDF；
3. 不把本机绝对路径写入测试；
4. 在最终报告中记录真实文件是否通过；
5. 对真实文件中出现的变量名、坐标名或单位差异，不得通过专门硬编码绕过，应抽象为明确规则。

如果当前环境没有真实下载文件，应明确说明未执行真实文件校验，不要伪造结果。

十六、文档更新

更新 README，说明：

- 如何执行数据内容校验；
- 校验检查了什么；
- warning 与 error 的区别；
- 校验不等同于完整气象质量控制；
- 原始数据不会被修改；
- 如何输出 JSON 报告。

十七、验收命令

至少执行：

```
uv sync --locked
uv run ruff check .
uv run mypy
```

```
uv run pytest
uv run weather-ai data validate --help
```

如果存在真实下载文件，再执行实际校验命令。

十八、最终输出

完成后报告：

1. 修改摘要；
2. 修改文件列表；
3. NetCDF 后端选择；
4. 数据模型和校验规则；
5. CLI 示例；
6. 测试数量和结果；
7. 是否验证了真实 ERA5 文件；
8. 真实文件的变量名、维度、坐标和单位摘要；
9. 已知限制；
10. 下一步建议。

不得继续实现 M2、累计降水、数据切分、PyTorch Dataset 或模型代码。